

1. Introdução e Contextualização

Este projeto tem como objetivo desenvolver um modelo preditivo robusto para o IBC-Br (Índice de Atividade Econômica do Banco Central), amplamente utilizado pelo mercado financeiro e acadêmico como *proxy* mensal de alta frequência para o Produto Interno Bruto (PIB) brasileiro. Dada a defasagem temporal na divulgação do PIB oficial trimestral (IBGE), o IBC-Br atua como um termômetro ágil, essencial para a tomada de decisão em política monetária e alocação de ativos.

A abordagem adotada fundamenta-se em técnicas de Machine Learning supervisionado, com foco na construção de um **Stacking Ensemble**. Esta estratégia combina previsões de múltiplos modelos heterogêneos para mitigar a variância do erro e ampliar a capacidade de generalização fora da amostra (*out-of-sample*). A metodologia inspira-se no estudo de Micheletti (2024), avançando na literatura ao implementar um meta-learner com restrições de não-negatividade (NNLS) e rigorosos testes de estacionariedade.

2. Engenharia de Dados e Metodologia

2.1. Fonte e Tratamento Inicial

A base de dados utilizada neste estudo foi compilada através da plataforma **Macrodados**, um sistema agregador de informações econômicas e financeiras. A amostra compreende séries temporais mensais extraídas de fontes primárias oficiais, notadamente o Banco Central do Brasil (BCB), o Instituto Brasileiro de Geografia e Estatística (IBGE), a Fundação Getúlio Vargas (FGV) e a B3.

O processamento inicial dos dados brutos (*dados_macro_bruto.xlsx*) foi executado através de um *pipeline* dedicado (*pipeline.py*), responsável pela limpeza dos dados, tratamento de *outliers* e preenchimento de valores ausentes (*imputation*),

assegurando a continuidade e a integridade das séries temporais antes da etapa de modelagem.

2.2. Feature Engineering (Engenharia de Atributos)

Para capturar a complexidade estrutural da economia brasileira, foram geradas novas variáveis explicativas fundamentadas na teoria econômica:

- **Juro Real:** Diferença entre a taxa Selic e a inflação (IPCA), mensurando o custo real do capital.
- **Termos de Troca:** Relação entre preços de exportação e importação (ou taxa de câmbio), indicando a riqueza relativa do país frente ao exterior.
- **Hiatos do Produto:** Diferença entre o nível atual do IBC-Br e suas tendências de longo prazo (médias móveis de 12 e 24 meses), sinalizando o aquecimento ou ociosidade da economia.
- **Volatilidade Financeira:** Desvio padrão móvel do Dólar e do Ibovespa (em janelas de 3 e 6 meses) como *proxy* para a incerteza de mercado.
- **Defasagens (Lags):** Variáveis defasadas em 3 e 12 meses para capturar a inércia inflacionária e os ciclos sazonais da atividade.

2.3. Transformação e Estacionariedade

Modelos de regressão linear e de árvores performam melhor ou exigem séries estacionárias (com média e variância constantes no tempo). Para tal, aplicou-se um protocolo de transformação específico por tipo de variável:

- **Diferenciação (*Diff*):** Aplicada a taxas percentuais (ex: Selic, Juro Real).
- **Log-retorno (*Pct Change*):** Aplicado a índices de preços e de atividade para normalizar a escala e estabilizar a variância.
- **Preservação de Nível:** Variáveis estruturais como "Hiatos" e "Balança de Empregos" foram mantidas em nível, conforme a teoria econômica sugere estacionariedade ou relevância direta de sua magnitude.

2.4. Seleção de Features via Teste ADF

A seleção de variáveis foi conduzida de forma automatizada (módulo `feature_selection.py`), utilizando o **Teste Augmented Dickey-Fuller (ADF)** como critério rigoroso de filtragem para evitar regressões espúrias — fenômeno onde o modelo detecta falsas correlações entre variáveis que possuem tendências estocásticas comuns, mas sem causalidade real.

O teste ADF verifica a presença de raiz unitária na série temporal. Adotou-se um nível de significância de 5% ($\alpha = 0.05$).

- **Critério de Decisão:** Se o p-valor calculado for menor que 0.05, rejeita-se a hipótese nula de raiz unitária, confirmando estatisticamente que a série é estacionária.

Resultado da Filtragem:

O algoritmo avaliou as 100 *features* geradas na etapa de engenharia. Destas, 15 variáveis falharam no teste ($p\text{-valor} > 0.05$), incluindo agregados monetários em nível (M1) e tendências de longo prazo, sendo descartadas. Restaram **85 variáveis explicativas** comprovadamente estacionárias para o treinamento dos modelos.

2.5. Arquitetura dos Modelos Base

A implementação utilizou as bibliotecas *Scikit-Learn* e *XGBoost*, com reprodutibilidade garantida pela fixação da semente aleatória (`random_state=42`). A calibração de cada algoritmo envolveu otimização de hiperparâmetros via *GridSearchCV* com validação cruzada temporal (*TimeSeriesSplit*). O sistema adotou uma lógica adaptativa: busca em grade para janelas com amostras suficientes e parâmetros conservadores para janelas iniciais curtas, visando evitar o overfitting.

As configurações específicas exploradas foram:

1. **Random Forest Regressor:** Otimização do número de árvores (150, 200) e

controle de profundidade (*max_depth*: 5, 7). Utilizou-se a raiz quadrada das *features* em cada divisão para descorrelacionar as árvores.

2. **Gradient Boosting Regressor**: Foco em taxas de aprendizado lentas (*learning_rate*: 0.01, 0.05) combinadas com subamostragem estocástica (0.7) e árvores rasas.
3. **ElasticNet**: Regularização híbrida, explorando penalidades (*alpha*) e taxas de mistura (*l1_ratio*) para transitar entre a seleção de variáveis (Lasso) e a redução de coeficientes (Ridge).
4. **XGBoost (XGB)**: Implementado com paralelismo e regularização adicional via amostragem de colunas por árvore (*colsample_bytree*: 0.7).

2.6. Estratégia de Validação e Stacking (Meta-Learner)

A estrutura de treinamento foi desenhada para mitigar o risco de vazamento de dados (*data leakage*), replicando o cenário real de previsão econômica.

Protocolo de Janela Expansiva (*Expanding Window*):

O pipeline implementou um *loop* iterativo de validação:

1. **Inicialização**: Treino com janela mínima de 48 meses.
2. **Ciclo de Previsão**: O modelo é treinado com dados de t_0 até t_{n-1} para prever t_n .
3. **Padronização Isolada**: O *StandardScaler* é ajustado apenas nos dados de treino da janela corrente, impedindo que estatísticas futuras contaminem o passado.
4. **Expansão**: O dado real é incorporado e a janela avança em um mês.

Construção do Meta-Learner via NNLS:

Para combinar as previsões dos modelos base, adotou-se o método de *Blending* otimizado via **Non-Negative Least Squares (NNLS)**. Diferente de uma regressão

linear comum, o NNLS restringe os pesos para serem estritamente positivos.

- **Interpretação Econômica:** Isso garante que um modelo só receba peso se contribuir positivamente para a redução do erro. Modelos redundantes ou de baixa performance têm seus pesos zerados matematicamente, funcionando como um mecanismo automático de seleção de modelos (Ensemble Seletivo).

3. Análise de Resultados

3.1. Performance Preditiva e Benchmark

A avaliação de desempenho utilizou o erro no nível do índice IBC-Br. Como *benchmark* de linha de base, adotou-se o Modelo Naive, que obteve um RMSE de **3.58**.

O modelo **Stacking Ensemble** superou consistentemente o benchmark e os modelos individuais na maioria dos cenários. No horizonte de 1 mês, o modelo atingiu um **MAPE de 1.86%** e um **RMSE de 2.48**, situando-se na faixa de alta precisão para previsões macroeconômicas.

Horizonte	Ensemble (Stacking)	Random Forest	Gradient Boosting	XGBoost	p-valor DM (Ensemble vs RF)
1 Mês	2.48	2.61	2.53	2.43	0.0004
3 Meses	2.37	2.56	2.42	2.41	0.0011

6 Meses	2.77	2.95	2.79	2.79	0.0100
12 Meses	2.41	2.59	2.44	2.43	0.0014

3.2. Sazonalidade e Horizontes Longos

Um fenômeno relevante é observado na comparação entre os horizontes de 6 e 12 meses. O erro do modelo aumentou no horizonte de 6 meses (RMSE 2.77), mas reduziu-se significativamente no horizonte de 12 meses (RMSE 2.41).

Este comportamento explica-se pela natureza da série do IBC-Br utilizada (sem ajuste sazonal). No horizonte de 6 meses, o modelo enfrenta a dificuldade de projetar meses de alta atividade utilizando defasagens de meses de baixa atividade (sazonalidade invertida). Já em 12 meses, os algoritmos capturam a forte autocorrelação anual da economia, onde o padrão de um mês no ano anterior serve como um preditor robusto para o mesmo mês no ano corrente.

3.3. Análise de Resíduos e Choques Exógenos

A análise dos resíduos demonstrou que os maiores erros de previsão não decorrem de falhas sistemáticas do modelo, mas sim de choques exógenos imprevisíveis (Cisnes Negros).

Data (Mês/Ano)	Erro Absoluto (IBC-Br)	Evento Macroeconômico	Justificativa Econômica do Resíduo
---------------------------	---------------------------------------	----------------------------------	---

Abril/2020	11,19	Início da Pandemia (COVID-19)	Choque exógeno inédito com paralisação abrupta do setor de serviços (lockdowns).
Março/2010	9,11	Retomada em "V" (Pós-Subprime)	Crescimento econômico acelerado por fortes estímulos fiscais e monetários do governo.
Março/2023	7,18	Super Safra Agrícola	Safra recorde de soja que impulsionou o PIB acima das projeções baseadas em indústria/serviços.
Maiio/2018	6,42	Greve dos Caminhoneiros	Choque negativo de oferta devido à paralisação logística nacional, quebrando a tendência da série.
Março/2022	6,24	Reabertura e Guerra da Ucrânia	Choque inicial de commodities da guerra.

Destacam-se os desvios em **Abril/2020** (Início da Pandemia/Lockdowns) e **Maior/2018** (Greve dos Caminhoneiros). Nesses episódios de quebra estrutural, a inércia histórica perde poder preditivo, evidenciando que modelos estatísticos devem ser complementados pela análise qualitativa em períodos de crise.

3.4. Validação Estatística (Teste Diebold-Mariano)

Para atestar a robustez dos resultados, aplicou-se o teste de Diebold-Mariano. Os resultados rejeitaram a hipótese nula de igualdade preditiva entre o Ensemble e o Random Forest com um p-valor de **0.0004** (confiança > 99,9%), comprovando a superioridade estatística da abordagem de Stacking. Em relação ao Gradient Boosting, houve empate técnico, sugerindo que o Ensemble atua principalmente como um redutor de variância e risco.

4. Conclusão

O estudo atingiu seu objetivo principal de desenvolver um sistema de *nowcasting* para a atividade econômica brasileira (IBC-Br) utilizando técnicas avançadas de Machine Learning. O modelo final (*Stacking Ensemble*) demonstrou alta capacidade preditiva, registrando um **MAPE de 1.86%** e um RMSE de **2.41** no horizonte de 12 meses. Mais importante, o modelo superou com ampla margem o *benchmark* ingênuo (Modelo Naive, RMSE 3.58), comprovando que a estrutura proposta é capaz de extrair sinais complexos das variáveis macroeconômicas e não apenas replicar a inércia da série.

A validação estatística via teste de **Diebold-Mariano** forneceu robustez aos achados. Com um p-valor de **0.0004**, rejeitou-se a hipótese nula de equivalência entre o Ensemble e o Random Forest, confirmando a superioridade da estratégia de

empilhamento. Em relação ao Gradient Boosting, observou-se um empate técnico estatístico, sugerindo que o ganho do Ensemble reside na **redução de variância** e na proteção contra o risco de especificação de um único modelo, atuando como um "seguro" contra instabilidades.

Do ponto de vista econômico, a análise revelou dois comportamentos cruciais:

1. **Sazonalidade e Horizontes:** O modelo capturou com precisão a forte autocorrelação anual da economia brasileira, apresentando erros menores no horizonte de 12 meses (RMSE 2.41) do que no de 6 meses (RMSE 2.77), contornando a ausência de ajuste sazonal na série bruta.
2. **Limitações em Choques Exógenos:** A análise de resíduos identificou que os maiores erros de previsão coincidem estritamente com eventos de quebra estrutural ("Cisnes Negros"), como a Greve dos Caminhoneiros (2018) e o início da Pandemia de COVID-19 (2020). Isso evidencia que, embora o algoritmo seja eficaz em condições normais de mercado, ele deve ser complementado pela análise qualitativa em cenários de crise inédita.

Por fim, ao contrastar estes resultados com a literatura recente, especificamente **Micheletti (2024)**, este trabalho apresenta contribuições metodológicas relevantes:

- **Evolução do Meta-Learner:** Diferente da abordagem de Regressão Linear utilizada por Micheletti, que pode resultar em *overfitting* por permitir pesos negativos, a implementação do **Non-Negative Least Squares (NNLS)** garantiu que o Ensemble atribuisse pesos nulos a modelos ineficientes (como o ElasticNet), assegurando uma performance sempre igual ou superior ao melhor modelo base.
- **Rigor no Pré-Processamento:** A filtragem sistemática via teste **ADF (Augmented Dickey-Fuller)** eliminou ruídos de tendências estocásticas, prevenindo regressões espúrias que frequentemente inflacionam métricas em estudos de séries temporais.

Conclui-se, portanto, que a arquitetura de *Stacking Ensemble* proposta, quando fundamentada em rigor estatístico e engenharia de dados econômica, consolida-se como uma ferramenta robusta e competitiva para o acompanhamento da atividade econômica brasileira.